Reinos de Pixelia

Una GAN que inventa habitantes para un RPG de fantasía medieval en pixel art

Pixelia es un mundo de fantasía medieval en **pixel art de 16 bits**, como los RPG clásicos. Sus habitantes (guerreros, magos, aldeanos, exploradores) aparecen de **cuerpo completo**, en **64×64 px**, sobre fondo neutro y vistos desde uno de **cuatro ángulos**.

Rasgos esperados (la vara con la que juzgamos la galería):

- silueta humanoide legible: cabeza, torso, brazos y piernas
- paleta limitada con contornos oscuros
- vestimenta variada: túnicas, armaduras, capuchas, cabello y tonos de piel diversos
- personajes distintos entre sí y que no copien el conjunto de entrenamiento

Integrantes: Mario Rocha · Luis Pedro Lira — Deep Learning 2026, UVG



64 sprites reales de TinyHero (datos de entrenamiento)

Datos: TinyHero

Aspecto	Detalle
Origen	TinyHero (github.com/AgaMiko/pixel_character_generator), generado con el Universal LPC Spritesheet (github.com/makrohn/Universal-LPC-spritesheet)
Licencia	Dual **CC-BY-SA 3.0 / GNU GPL 3.0**: permite usar y modificar citando la fuente. Sin rostros de personas reales ni personajes protegidos.
Tamaño	**3,648** sprites RGBA de 64×64 px, 912 por cada vista (frente, espalda, izquierda, derecha)
Preparación	RGBA compuesto sobre **fondo blanco** (78 % de los píxeles quedan exactamente blancos). Sin recorte ni redimensionamiento (ya miden 64×64). Normalización a [−1, 1] para la salida tanh.
Aumento	**Volteo horizontal** (p = 0.5): coherente porque las vistas izquierda y derecha son espejo una de otra. Por eso la prueba de vecinos busca también entre las imágenes volteadas.
Reproducibilidad	Semilla de entrenamiento 2026 (random, numpy, torch y orden del DataLoader); ruido fijo de evaluación: 16 z con semilla 7; métricas: 1,000 z con semilla 123; galería: semillas 0–199.



Por qué este conjunto: estilo muy consistente (misma plantilla corporal y paleta LPC) y pocos miles de imágenes, como recomienda el enunciado. Esa misma homogeneidad resultó un riesgo: la «silueta promedio» atrae al generador.

Arquitectura y diseño experimental

Base: DCGAN 64×64 (Radford et al., 2016). La elegimos por ser la referencia convolucional, caber en el cómputo y permitir que cada experimento sea **un solo cambio**.

- **G:** $z \in \mathbb{R}^{100}$ → ConvT 4→8→16→32→64 px, BatchNorm + ReLU, salida tanh
- **D:** Conv stride 2 + LeakyReLU(0.2) + BatchNorm → 1 logit
- Adam(2e-4, β=(0.5, 0.999)), batch 64, ngf = ndf = 64, init N(0, 0.02)

Modelo final: WGAN-GP (Gulrajani et al., 2017), elegido tras diagnosticar el colapso (diap. 8): mismo G; crítico **sin BatchNorm y con sesgos**, λ = 10 (penalización de gradiente), 5 pasos del crítico por paso de G, Adam(1e-4, β=(0, 0.9)); ngf = ndf = 32 y 270 épocas (≈3,000 pasos de G) por el costo en CPU.

Por qué WGAN-GP: el crítico evalúa cada muestra por separado (sin BatchNorm) y la distancia de Wasserstein da gradientes útiles aunque reales y falsos no se solapen, justo lo que faltaba en las DCGAN.

Corrida	Cambio único vs. control	Épocas
base	— (control: BCE no saturante, BN en D)	10
hinge	pérdida hinge	10
sn	normalización espectral en D (sin BN)	10
mbstd	capa minibatch-std en D	10 (+10)
noise	ruido gaussiano en entradas de D (σ 0.1→0)	10 (+5)
ttur	lr de D = 5e-5 (G = 2e-4)	10 (+5)
sn_bias	sn + sesgos en D (control: sn)	10
wgangp	modelo final (varios cambios: no es experimento controlado)	270

Protocolo: las 7 corridas DCGAN se comparan en el **checkpoint de la época 10** (570 iteraciones) con la misma semilla, los mismos datos y el mismo ruido fijo. Métricas con 1,000 muestras: **FID-ResNet18** (Fréchet sobre features de ResNet18; no comparable con el FID de Inception) y **diversidad** = 1 − coseno medio entre pares (reales: 0.274).

Experimento de pérdida: hinge vs. BCE no saturante

Hipótesis previa (escrita antes de entrenar):

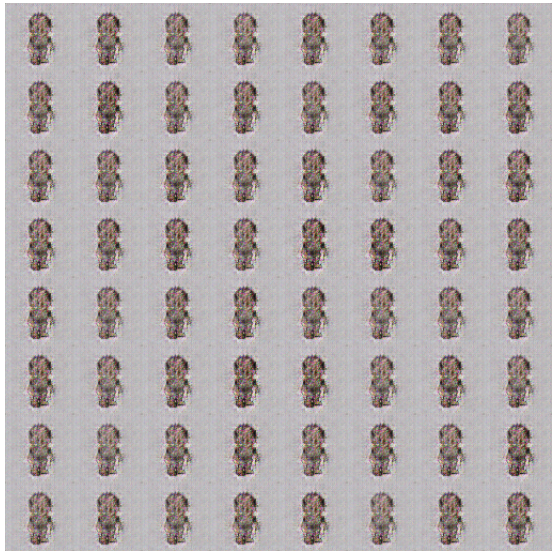
«Creemos que la pérdida hinge mejorará la estabilidad y la diversidad porque solo penaliza los logits que no superan el margen, así D deja de empujar hacia confianzas extremas. Lo consideraremos útil si la FID-ResNet18 baja, la diversidad aumenta y la pérdida de D no se queda cerca de cero.»

Control: misma semilla, datos y épocas	base (BCE)	hinge
FID-ResNet18 ↓	1.151	1.034
Diversidad ↑ (real 0.274)	0.016	0.024
% iteraciones con pérdida D < 0.05	24 %	38 %*

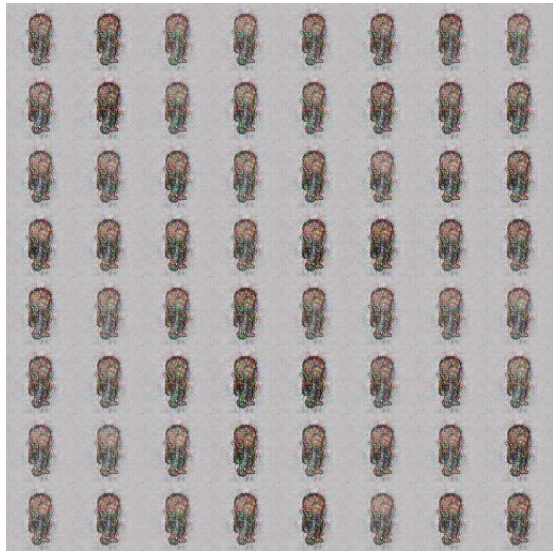
Resultado: la hipótesis se cumplió **solo en parte**. La FID bajó 10 % y la diversidad subió 50 %, pero sigue un orden de magnitud por debajo de la real y **el colapso persiste**: D sigue ganando (el margen se cumple en ambos lados en el 38 % de las iteraciones).

Conclusión: cambiar la pérdida suaviza el juego pero no basta; el problema de fondo estaba en el discriminador (diap. 8). Más adelante, la pérdida de Wasserstein (WGAN-GP) sí rompió el colapso.

* En hinge, pérdida de D = 0 significa que se cumple el margen con reales y falsos: el equivalente a que D «gane».



base (época 10)



hinge (época 10)

Lectura visual: ambas producen la misma silueta oscura y ruidosa en las 64 muestras. La mejora numérica de hinge no se traduce en personajes distintos; por eso, además de la FID, medimos la diversidad y miramos la rejilla de ruido fijo.

Experimentos de estabilización

Hipótesis previa (principal, normalización espectral en D):

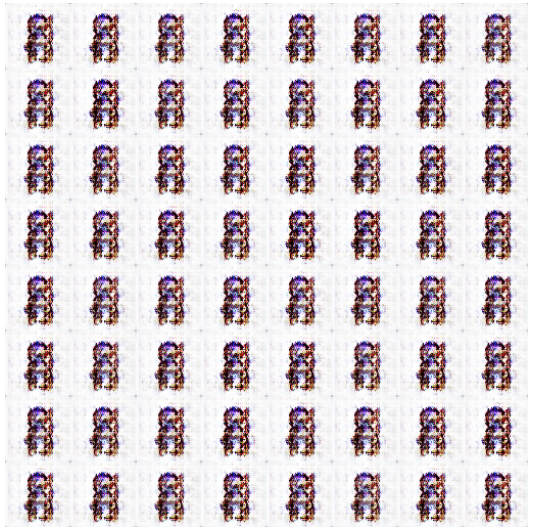
«Creemos que la normalización espectral en D mejorará la estabilidad y la diversidad porque acota la constante de Lipschitz de D y evita que domine a G. Lo consideraremos útil si las curvas se estabilizan enfrentadas, la FID baja y la rejilla de ruido fijo muestra filas distintas.»

Corrida	FID ↓	Divers. ↑	Fondo (real 1.00)	% D<0.05	¿Se cumplió la hipótesis?
base	1.151	0.016	0.48	24 %	control
sn	**1.027**	**0.023**	**0.19**	**0 %**	**parcial: mejor FID y curvas enfrentadas, pero colapso**
mbstd	1.160	0.018	0.42	46 %	no: D domina más
noise	1.065	0.020	0.71	45 %	no: D domina más
ttur	1.174	0.015	0.47	0 %	parcial: equilibrio, sin diversidad
sn_bias	0.915	0.013	0.93	0 %	sí en fondo y color; no rompe el colapso (no se esperaba)

Resultado: SN fue la mejor DCGAN (menor FID, nunca D < 0.05) pero **la rejilla siguió colapsada**. Los 3 experimentos extra (un solo cambio cada uno, con hipótesis previa en el notebook) tampoco lo evitaron. **sn_bias** recuperó fondo blanco y color (logit medio de los falsos ≈ 0 → −0.74): confirma la causa A de la diap. 8.



sn (época 10): gris, sin color

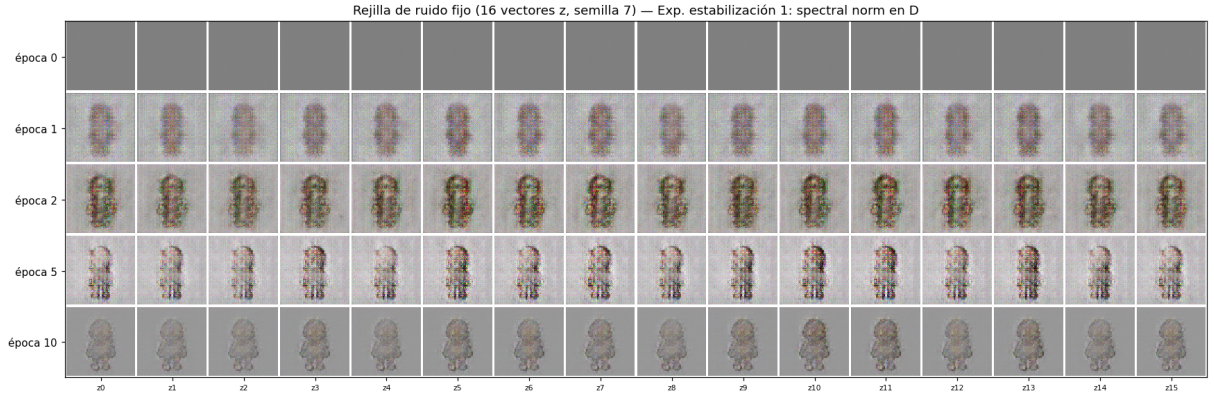


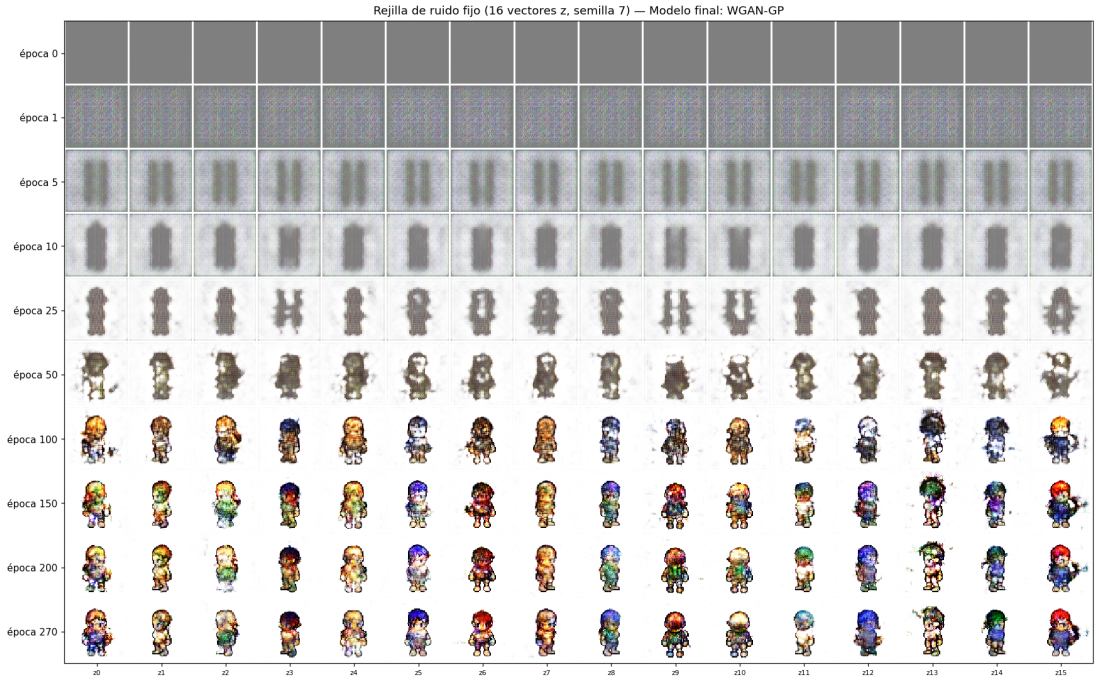
sn_bias (época 10): fondo y color

Por qué las curvas «sanas» de SN engañaban: sin BatchNorm y sin sesgos, D es homogénea: D(c·x) = c·D(x). G produjo imágenes grises cercanas a 0, donde D da logit ≈ 0 y D(G(z)) ≈ 0.5: **parecía equilibrio, era un punto muerto**. Fondo medio de sn: 0.19; con sesgos: 0.93.

Evidencia 1: rejilla de ruido fijo

16 vectores z fijos (semilla 7) a lo largo del entrenamiento





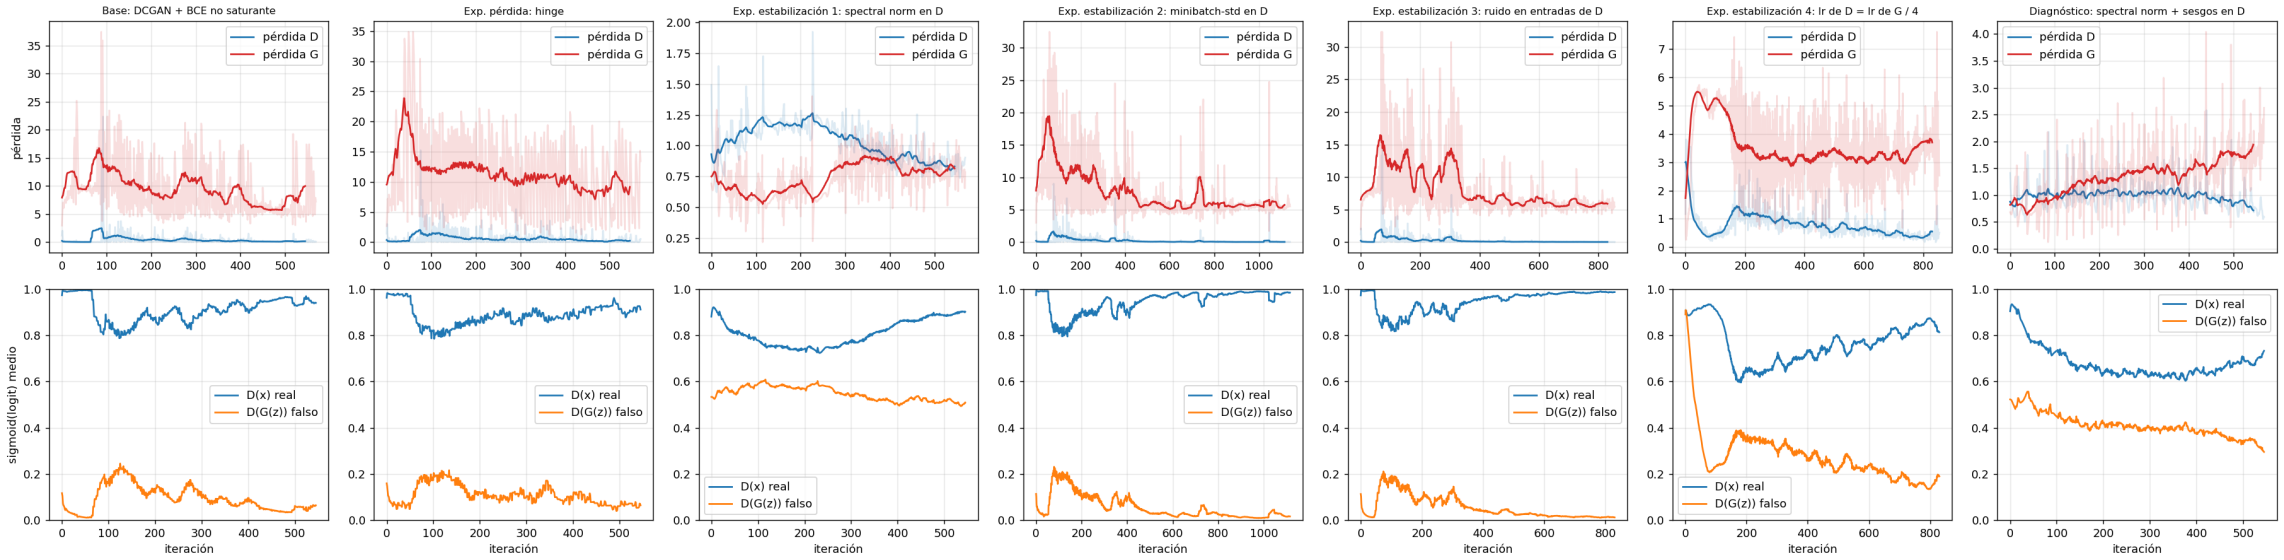
Cómo se lee: cada columna es el mismo z; cada fila, una época. Si las columnas se vuelven iguales, G ignora z: **colapso de modos**.

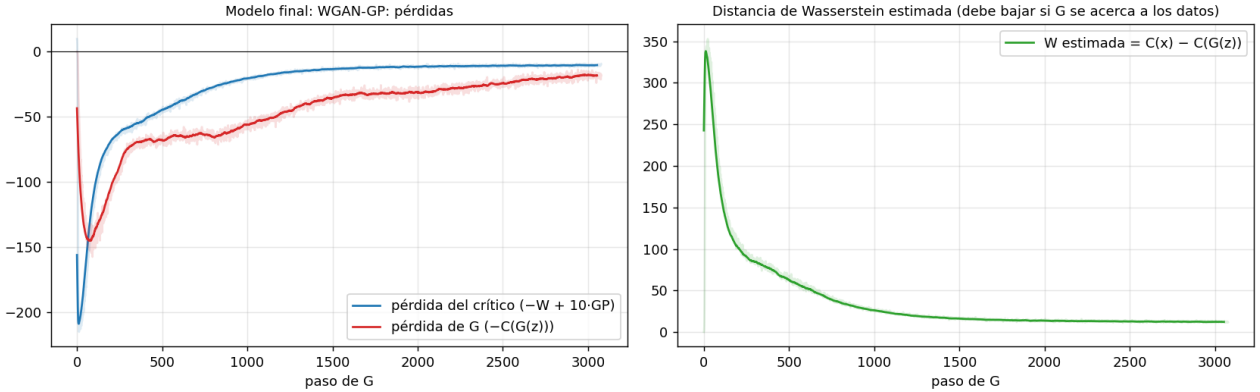
DCGAN (arriba, sn; las demás en el anexo): desde la época 2–5 las 16 columnas son el mismo personaje. Pasa en **todas** las configuraciones DCGAN, también con minibatch-std y TTUR.

Modelo final WGAN-GP (abajo): desde la época 25 cada columna tiene una silueta distinta (ancho, piernas, cabeza); hacia la época 100 aparecen el color y los detalles (cabello rojo, verde, azul o blanco; varias vistas), y las columnas **no convergen** entre sí hasta la época 270. Es la única corrida sin colapso: diversidad 0.221 (real 0.274) frente a 0.012–0.024 de todas las DCGAN.

Evidencia 2: curvas de pérdida interpretadas

G y D deben estabilizarse enfrentadas, no bajar juntas



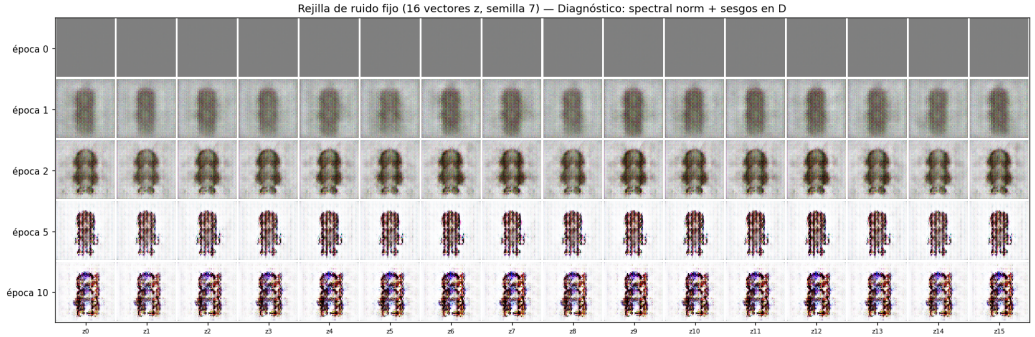


DCGAN (arriba): en base, hinge, mbstd y noise la pérdida de D cae casi a 0 y la de G se dispara (5–20) con D(G(z)) < 0.1: **D gana**, señal de alarma. En sn y ttur se ven «enfrentadas», pero con colapso: **curvas sanas no garantizan diversidad**.

WGAN-GP (abajo): la pérdida del crítico es negativa por diseño (−W + GP), así que la alarma «D cerca de 0» no aplica. La distancia de Wasserstein estimada baja de ~340 a ~12 en ~1,500 pasos de G y se estabiliza: G se acerca a los datos y el crítico no lo aplasta. Esta vez la curva sí coincide con la rejilla (sin colapso) y con la FID (0.181 frente a 1.027 de sn).

Problemas encontrados y decisiones

Problema	Evidencia	Decisión
Colapso en las 6 corridas DCGAN desde la época 2–5	rejillas idénticas; diversidad 0.012–0.024 vs. 0.274 real; la desviación entre muestras cae de 0.13 a 0.045 en 20 iteraciones	detener todas en la época 10 y comparar en igualdad de condiciones; probar 3 técnicas extra
¿Bug? (BN en eval, backend MPS, datos)	mismo resultado en train()/eval() y en CPU; G sí aprende el fondo blanco con pérdida L2 directa	descartado: no es un bug del código ni de los datos
Causa A: D sin sesgos ni BN en sn	D(0.25x)/D(x) = 0.25 exacto y D(0) = 0; gradiente sobre el fondo ~10^{-7}; logit de los falsos ≈ 0 todo el entrenamiento	experimento controlado **sn_bias**: fondo 0.19 → 0.93 y color, pero sigue colapsado
Causa B: D con BN ve reales y falsos en lotes separados	un lote falso sin variedad no se distingue tras normalizar; minibatch-std, TTUR y SN + hinge (pilotos) no alcanzaron	**WGAN-GP**: crítico sin BN que evalúa cada muestra; un piloto de 300 pasos de G lo confirmó
Cómputo: solo CPU, sin GPU	WGAN-GP hace 5 pasos de D por paso de G	ngf = ndf = 32 y 270 épocas (~2 h); checkpoints cada 10 épocas
Los 200 candidatos de sn eran idénticos	hoja de contacto con 200 copias del mismo personaje gris	no elegir una galería de copias: se toma del modelo final, declarando la tasa de selección



Rejilla de sn_bias (único cambio vs. sn: sesgos en D): desde la época 2 el fondo es blanco y hay color, pero las 16 columnas siguen siendo el mismo personaje. Arregla la causa A, no la B.

Lección: las curvas «sanas» de sn engañaban y la FID sola tampoco bastaba. Lo que destrabó el proyecto fue no conformarse con 200 candidatos idénticos y medir directamente: el fondo, la variación entre muestras, el logit de D para los falsos y la homogeneidad de D. Cada hipótesis de causa se puso a prueba con un experimento (sn_bias) o con pilotos antes de cambiar de arquitectura.

Galería final: 10 habitantes de Pixelia

10 de 200 (5 %) · runs/wgangp/G_final.pt



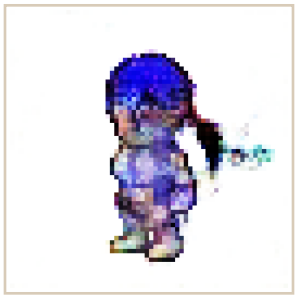
Rhosyn de Brasaviva
Aprendiz de herrera
#1 · semilla 60



Ivra Hojaverde
Druida del Bosque Musgoso
#2 · semilla 10



Corvin Sombrafría
Explorador nocturno
#3 · semilla 6



Nerea Mareaclara
Maga de las Mareas
#4 · semilla 66



Tobin Cardoverde
Guardabosques
#5 · semilla 83



Albarán el Escarchado
Vidente de la Escarcha
#6 · semilla 109



Garrik Forjarroja
Mercenario
#7 · semilla 13



Lysa Trigodorado
Escudera
#8 · semilla 168



Mirela de Valcastaño
Juglaresa
#9 · semilla 50



Ysolde Rosalba
Alquimista
#10 · semilla 54

Tasa de selección: 10 de 200 (5 %) candidatos (semillas 0–199 del modelo final; hoja completa en el anexo).

Criterio: revisamos a ojo los 200 y exigimos (1) silueta humanoide legible, (2) sin artefactos graves y (3) que no se parezcan entre sí en cabello, vista ni ropa. La sugerencia automática (greedy max-min en ResNet18) se descartó porque favorecía candidatos con artefactos. La semilla 64 se cambió por la 54 por parecerse a #6 (coseno 0.863).

Lectura: los 10 tienen silueta completa, contorno oscuro y fondo blanco, en cuatro vistas, con cabello y ropa distintos. Diversidad interna 0.237 (real 0.274); la pareja más parecida (#7–#8, coseno 0.897) se distingue a simple vista. **Defectos:** textura ruidosa y contornos menos limpios que el pixel art LPC.

Evidencia 3: prueba de vecinos más cercanos

Contra los 3,648 datos de entrenamiento y sus volteados



Método: features ResNet18 (ImageNet) normalizadas → coseno (argmax), y L2 en píxeles (argmin). **Referencia real→real** (cada imagen real contra su vecina real más cercana): coseno medio 0.952, p95 1.000. Un generado más parecido a su vecino que lo típico entre reales sería sospechoso de memorización.

Resultado: ningún personaje es copia. Los 10 cosenos (0.846–0.911) están bajo la media real (0.952) y entre el 79 % y el 99 % de los reales tiene un vecino real más parecido; en píxeles, L2 de 25.7–41.4 frente a una mediana real de 17.2. En 9 de 10 casos el vecino CNN y el vecino en píxeles son personajes distintos. La excepción es **#1 Rhosyn** (coseno 0.911): ambos vecinos son el mismo personaje real, #440, en dos vistas; comparte peinado y pose, pero no la armadura. El p95 = 1.0 de la referencia se debe a que el 10.7 % de los reales tiene un duplicado exacto en espejo.

Conclusiones, limitaciones y reflexión final

Conclusiones

• **Todas las DCGAN colapsaron** (base + 5 experimentos de un solo cambio + sn_bias). Hinge y SN mejoraron la FID, pero ninguna recuperó la diversidad.
• **Encontramos dos causas**: un D homogéneo en sn (sin sesgos ni BN), confirmado con sn_bias, y que BatchNorm en D no castiga lotes sin variedad.
• **WGAN-GP rompió el colapso**: FID 0.181 (5.7× menor), diversidad 0.221 (9.4× mayor que sn) y fondo correcto.
• La galería es **nueva** según los vecinos más cercanos y **coherente** con Pixelia.
• Ni las curvas sanas ni una sola métrica alcanzan: hacen falta la rejilla, la diversidad y los vecinos.

Limitaciones

• Solo CPU: el modelo final usa ngf = 32, y los experimentos controlados duraron 570 iteraciones; más tiempo podría cambiar el ranking.
• wgangp cambia varias cosas a la vez: sabemos que funciona, no cuál de los cambios es imprescindible.
• FID-ResNet18 no es el FID estándar, y ResNet18 no se entrenó con pixel art.
• El criterio de selección (10 de 200) es en parte subjetivo; por eso lo declaramos y lo apoyamos con cosenos.
• Textura ruidosa: los sprites no alcanzan la limpieza del pixel art hecho a mano.

Reflexión final. *De sus 10 personajes, ¿cuál le costó más defender como «nuevo» frente a su vecino más cercano? ¿Qué le dice ese caso sobre lo que su GAN aprendió de su universo?*

Rhosyn de Brasaviva (#1, semilla 60) fue el que más costó defender. Tiene el mayor coseno (0.911) y es el único cuyos dos vecinos son el mismo personaje real (#440): mismo cabello rojo, cara y pose. Lo nuevo es la ropa, una camisa blanca en lugar de armadura dorada, y aun así el 79 % de los reales tiene una vecina más parecida.

Qué aprendió la GAN: los sprites LPC se arman por capas (cuerpo, cabello, ropa, armas) sobre una plantilla común y cuatro vistas. La GAN aprendió esa **estructura combinatoria** y recombina capas, por eso inventa personajes en vez de copiarlos. Pero cuando una capa es rara, como este peinado, se pega a los pocos ejemplos que la tienen. Y aprendió mejor *qué* va en cada lugar (forma y color) que el *cómo* del pixel art, con contornos y texturas ruidosos.

En una frase: aprendió la gramática de Pixelia, todavía no su caligrafía.

Matriz de evidencias

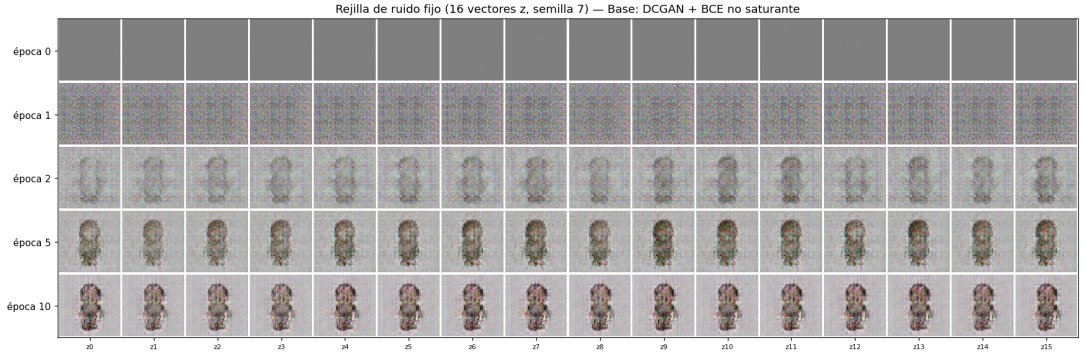
Evidencia	Diapositiva	Conclusión	Limitación
Rejilla de ruido fijo	6 (+ anexo)	Las 7 DCGAN colapsan desde la época 2–5 (16 columnas iguales); WGAN-GP mantiene 16 personajes distintos hasta la época 270.	16 z son una muestra pequeña; por eso la completamos con la diversidad sobre 1,000 muestras.
Curvas de pérdida	7	D gana en base, hinge, mbstd y noise; en sn y ttur las curvas «sanas» esconden colapso; en WGAN-GP la W estimada baja de ~340 a ~12 y se estabiliza.	Las curvas no miden diversidad, y la pérdida del crítico de WGAN no es comparable con la de BCE.
Prueba de vecinos más cercanos	10	Ningún personaje es copia: coseno 0.846–0.911 frente a una media real de 0.952; en 9 de 10, el vecino CNN y el de píxeles son personajes distintos. #1 es el más cercano (comparte peinado con el real #440).	ResNet18 no se entrenó con pixel art; la L2 castiga el ruido; la referencia está inflada por duplicados en espejo (10.7 %).
Galería y tasa de selección	9 (+ anexo)	10 de 200 (5 %) con criterio declarado; 10 personajes distintos (diversidad interna 0.237, real 0.274), coherentes con Pixelia y regenerables bit a bit (galeria.py verify).	Criterio en parte subjetivo; textura ruidosa frente al pixel art real.
Experimento de pérdida (hinge vs. BCE)	4	Hipótesis cumplida en parte: FID 1.151 → 1.034 y diversidad 0.016 → 0.024, pero el colapso persiste.	Solo 570 iteraciones por corrida; una sola semilla.
Experimento de estabilización (SN + mbstd, noise, ttur, sn_bias)	5 y 8	SN: mejor FID de las DCGAN, pero colapso. sn_bias confirma la causa A (fondo 0.19 → 0.93). Ninguna técnica sobre DCGAN evita el colapso; WGAN-GP sí.	Experimentos cortos (10 épocas); wgangp combina varios cambios, así que no aísla una sola causa.
Diagnóstico del colapso	8	Dos causas: un D sin sesgos ni BN es homogéneo (D(0.25x)/D(x) = 0.25, D(0) = 0) y BatchNorm en D no castiga lotes sin variedad. Justifican el cambio a WGAN-GP.	La causa B se apoya en pilotos cortos (300–800 iteraciones) fuera de runs/, no en corridas controladas completas.

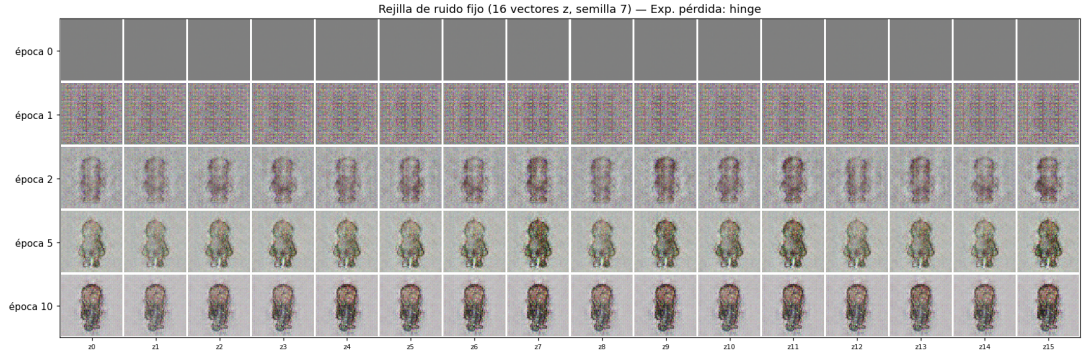
Anexo: 200 candidatos del modelo final

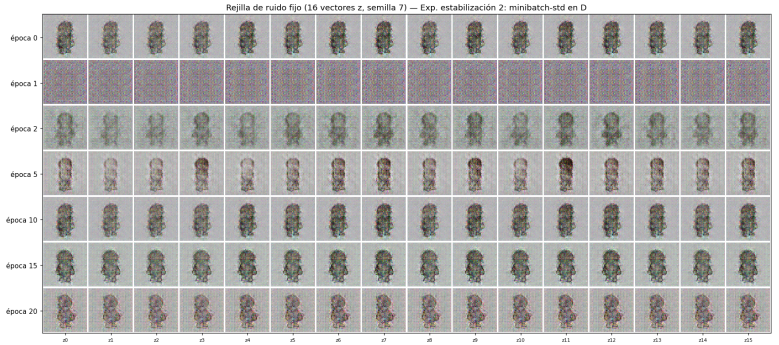


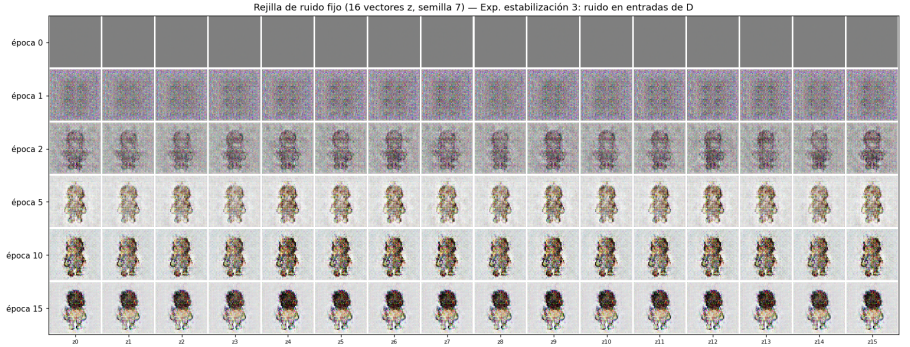
Anexo: rejillas de ruido fijo de las demás corridas DCGAN

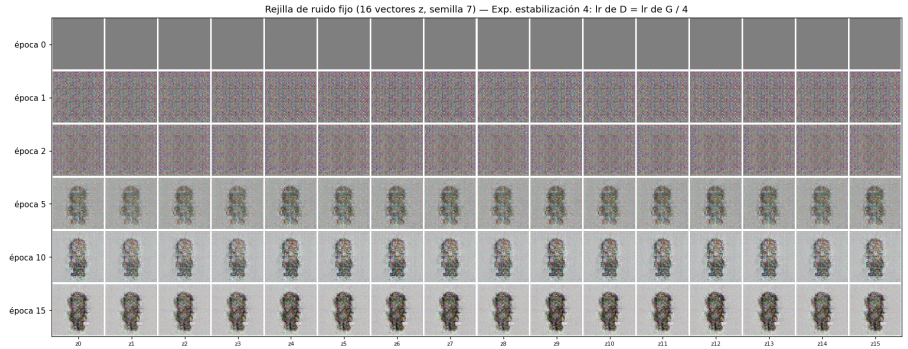
todas colapsan

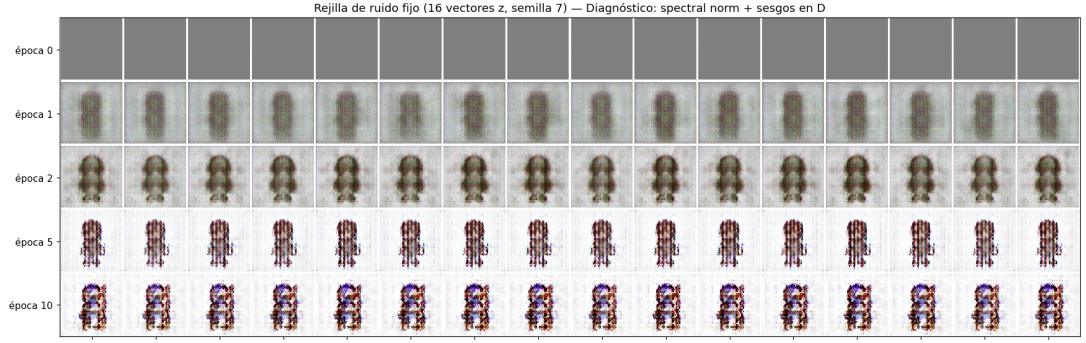






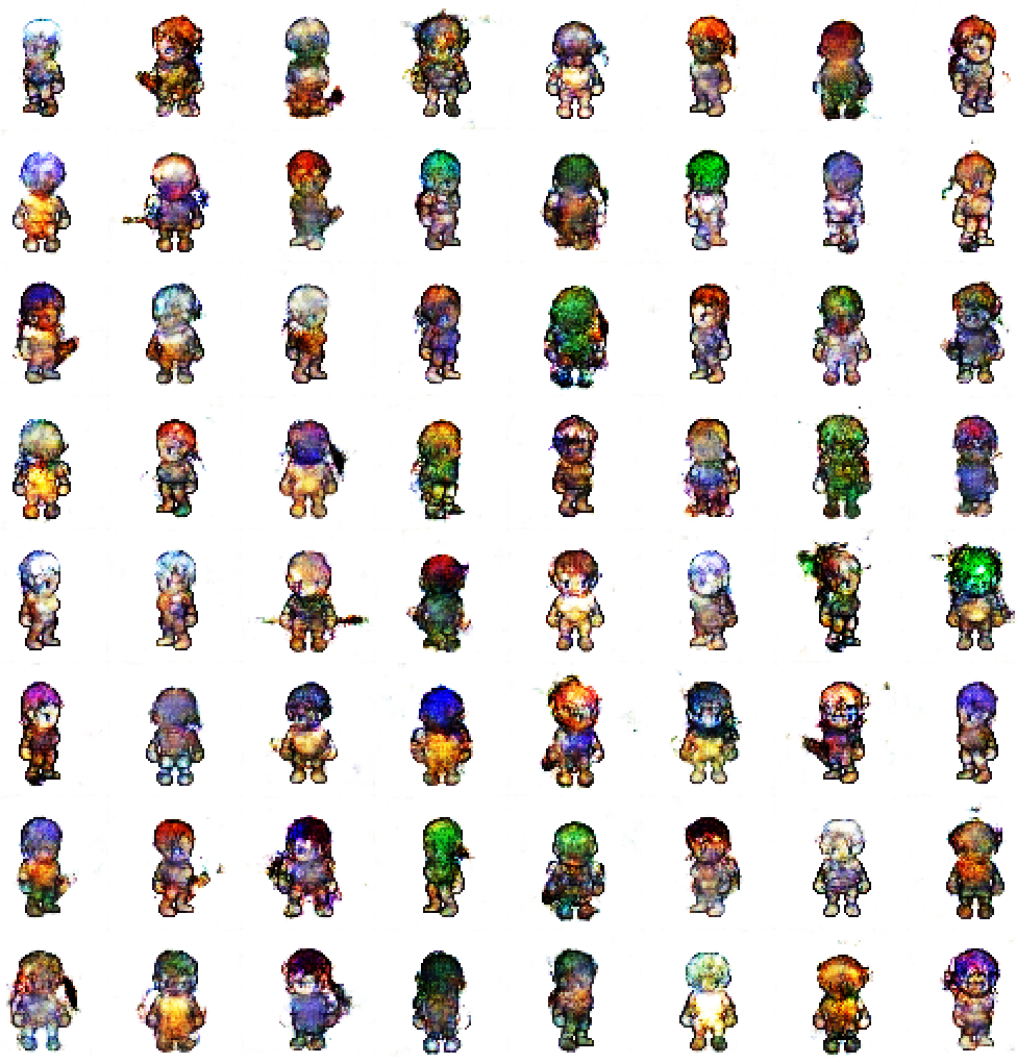






Anexo: muestras del modelo final vs. datos reales

64 muestras con la semilla 123



WGAN-GP (modelo final)



reales